

# PROYECTO FINAL – ARQUITECTURA MEDALLION CON AZURE + DATABRICKS

Autor: César Fernando Campos Millán

Curso: Ingeniería de Datos e IA con Databricks

Fecha: Noviembre 2025

## 1. Introducción

El presente proyecto implementa un flujo completo de procesamiento de datos utilizando la Arquitectura Medallion sobre Azure Databricks y Azure Data Lake Storage (ADLS).

El objetivo principal es construir un pipeline moderno y escalable que permita:

- Ingestar datos crudos desde ADLS
- Transformarlos mediante PySpark
- Organizar los datos en capas (Bronze, Silver, Gold)
- Publicar tablas curatoradas en Delta Lake
- Automatizar el ETL con Databricks Jobs
- Crear dashboards analíticos basados en la capa Gold

## 2. Arquitectura del Proyecto

El pipeline sigue la arquitectura Medallion:

RAW → BRONZE → SILVER → GOLD → Dashboards

Servicios utilizados:

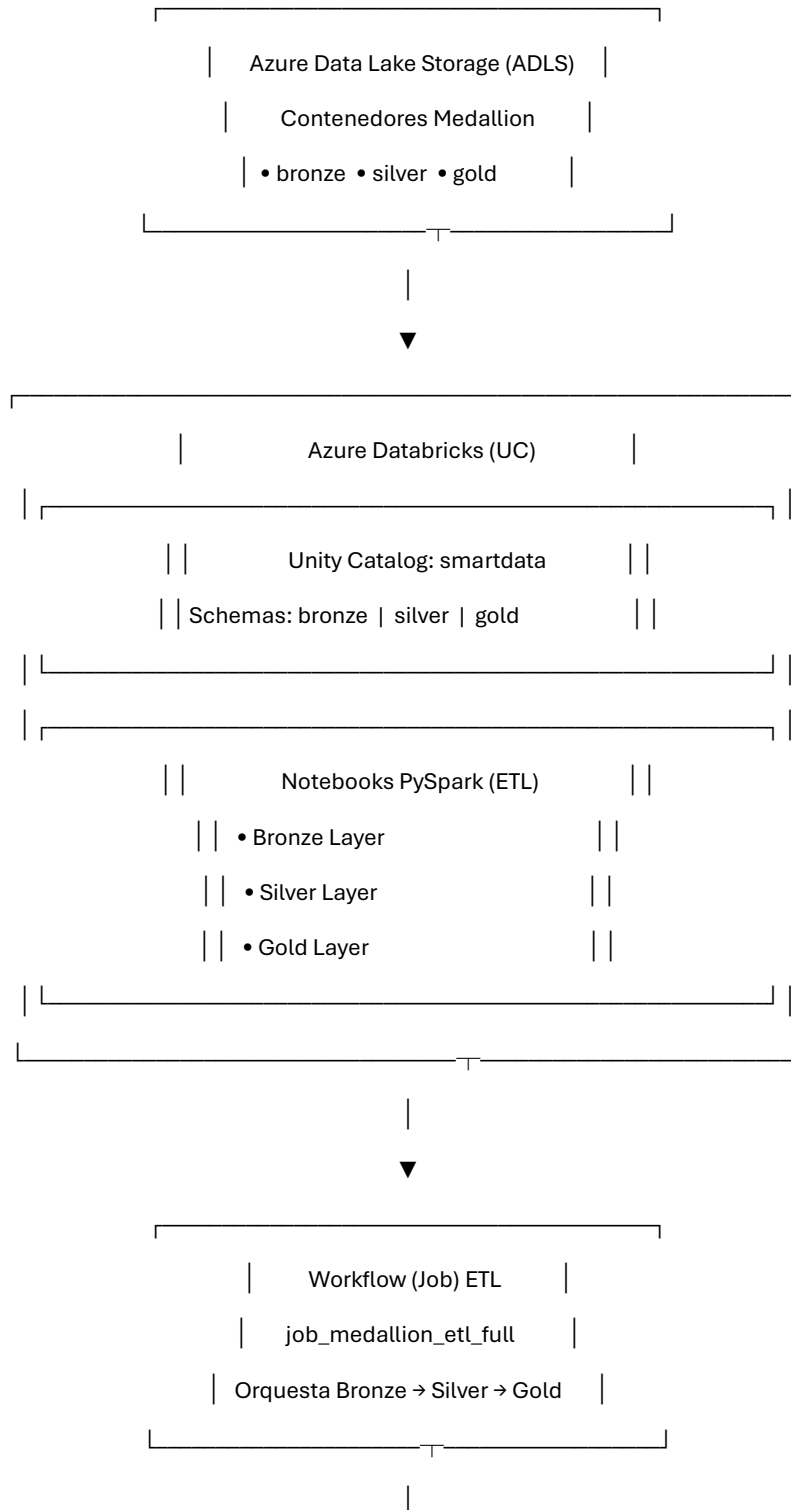
Azure Data Lake Storage Gen2 (ADLS)

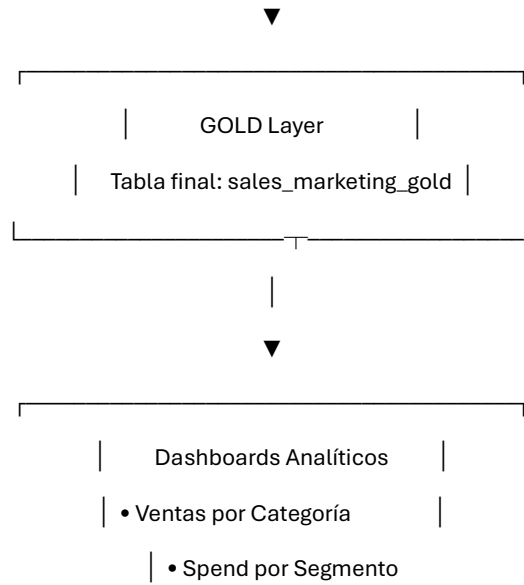
Azure Databricks (Unity Catalog)

Delta Lake

Databricks Jobs / Workflows

Databricks SQL Dashboards





### ☁️ 3. Azure Data Lake – Capa de Almacenamiento

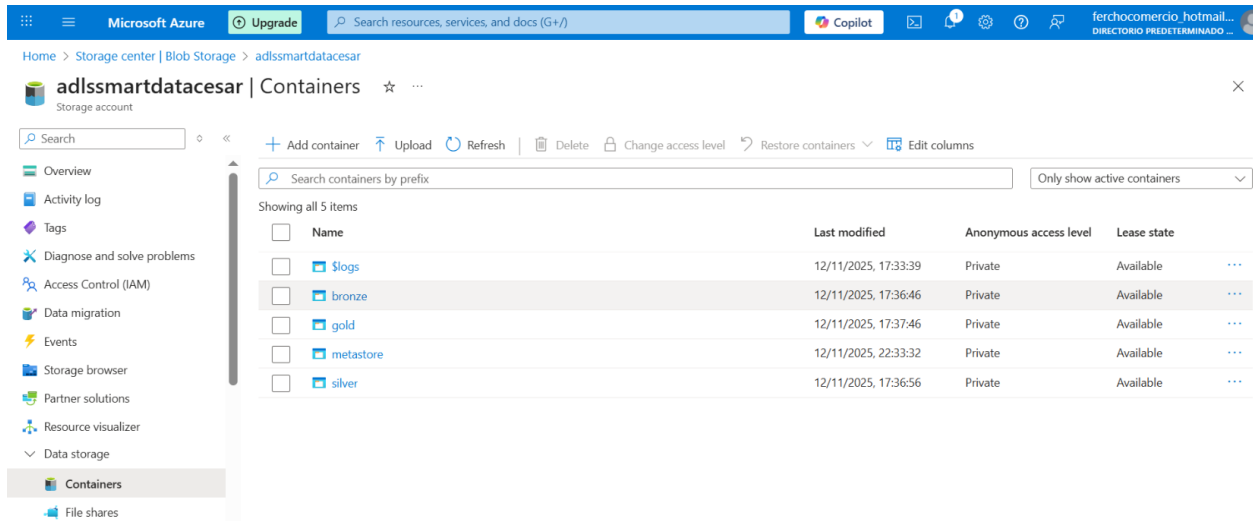
Se configuró un Storage Account con tres contenedores:

bronze

silver

gold

Cada contenedor representa una capa de la arquitectura Medallion.



#### 🏆 4. Capa BRONZE – Ingesta de Datos

En esta capa se almacenan los datos crudos provenientes de:

DBFS (marketing\_campaign.csv)

ADLS (Ecommerce\_Sales\_Prediction\_Dataset.csv)

Transformaciones realizadas:

Lectura en formato CSV

Inferencia automática de esquemas

Normalización mínima (renombrado de columnas cuando aplica)

Código ejemplo Bronze:

```
spark.sql("USE CATALOG smartdata")
```

```
spark.sql("USE SCHEMA bronze")
```

```
df_mkt_bronze = (  
    spark.read.format("csv")
```

```

.option("header", "true")
.option("inferSchema", "true")
.option("delimiter", "\t")
.load("dbfs:/FileStore/marketing_campaign.csv")
)
df_mkt_bronze.write.format("delta").mode("overwrite") \
  .saveAsTable("smartdata.bronze.marketing_raw")

```

Tablas generadas:

smartdata.bronze.marketing\_raw

smartdata.bronze.ecommerce\_raw

## 5. Capa SILVER – Limpieza y Estandarización

En esta etapa se realizan transformaciones para mejorar la calidad del dato.

Acciones principales:

Conversión de tipos: int, double, date

Corrección de formatos

Estandarización de columnas

Preparación para capa Gold

Código ejemplo Silver:

```

df_marketing_silver = (
  df_marketing
  .withColumn("Dt_Customer", F.to_date("Dt_Customer", "yyyy-MM-dd"))
  .withColumn("Income", F.col("Income").cast("int"))
)

df_marketing_silver.write.format("delta").mode("overwrite") \

```

```
.saveAsTable("smartdata.silver.marketing_campaign_silver")
```

## 6. Capa GOLD – Curación y Enriquecimiento

La capa GOLD contiene la versión “curada” y enriquecida del dato.

Acciones realizadas:

Cálculo de nuevas métricas:

Age

Total\_Spend

Net\_Price

Revenue

Generación de tabla final unificada para análisis:

smartdata.gold.sales\_marketing\_gold

Código ejemplo Gold:

```
df_gold = df_ecom_silver.crossJoin(df_mkt_silver)
df_gold = df_gold.withColumn("row_id", F.monotonically_increasing_id())

df_gold.write.format("delta").mode("overwrite") \
    .saveAsTable("smartdata.gold.sales_marketing_gold")
```

## 7. Unity Catalog – Gobernanza del Proyecto

Se organizó el catálogo:

Catálogo: smartdata

Schemas:

bronze

silver

gold

Tablas creadas:

marketing\_raw

ecommerce\_raw

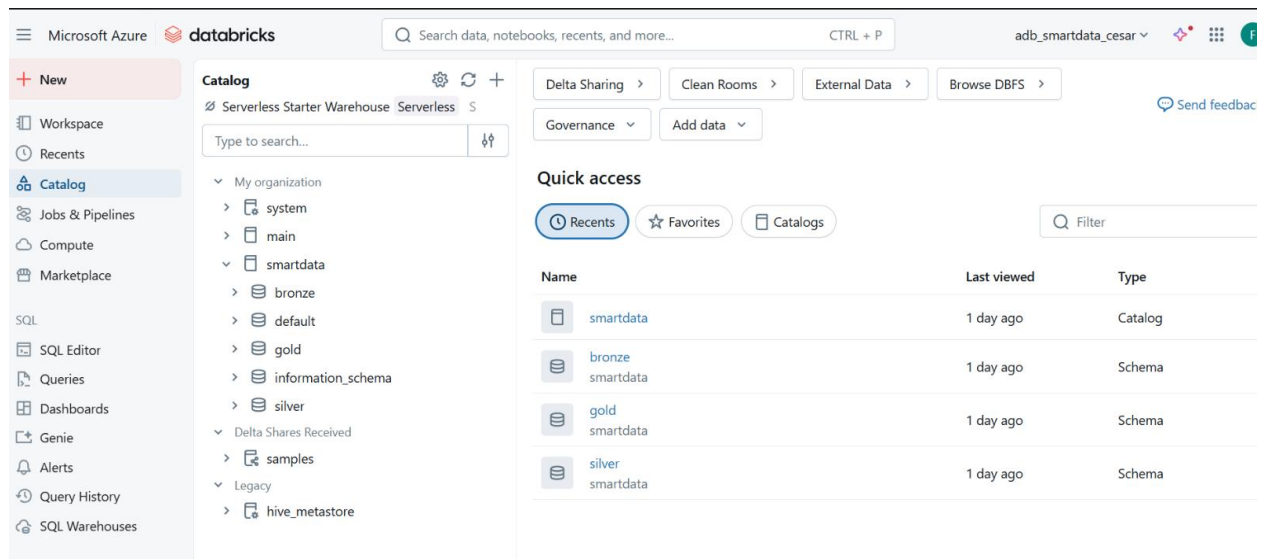
marketing\_campaign\_silver

ecommerce\_silver

marketing\_campaign\_gold

ecommerce\_gold

sales\_marketing\_gold



## 8. Databricks Workflow (Job)

Se implementó un job llamado:

 job\_medallion\_etl\_full

Este job ejecuta automáticamente las tres capas del ETL.

Funcionalidades:

Automatiza el pipeline

Orquesta Bronze → Silver → Gold

Permite ejecución manual o programada

Conecta al cluster de Databricks





The screenshot displays the Databricks Jobs & Pipelines interface. On the left, a sidebar contains navigation options: Workspace, Recents, Catalog, Jobs & Pipelines (selected), Compute, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie, Alerts, Query History, and SQL Warehouses. The main panel shows the job 'job\_medallion\_etl\_full' with a 'Run now' button. Below the job name, there are tabs for 'Runs' and 'Tasks'. The 'Runs' tab is active, showing a table of job runs. The table has columns: Start t..., Ru..., La..., Du..., Spark, Status, Error..., and Run ... The first row shows a successful run on Nov 1... at 25... Ma... with a duration of 2m 6s. The 'Spark' column contains links for 'UI / Logs / Metrics'. To the right of the table, there are sections for 'Job details' and 'Schedules & Triggers'. The 'Job details' section includes fields for Job ID (370658539120945), Creator (Fernando Campos), Run as (Fernando Campos), Description (Add description), Lineage (1 upstream table, 2 downstream tables), and Performance optimized (toggle off). The 'Schedules & Triggers' section shows 'None' and an 'Add trigger' button.


Start t...	Ru...	La...	Du...	Spark	Status	Error...	Run ...
Nov 1...	25...	Ma...	2m 6s	Spark UI / Logs / Metrics	✓ S...		

## 9. Dashboards – Análisis Final

Se generaron 3 visualizaciones desde la tabla Gold:

- ✓ Ventas por Categoría
- ✓ Marketing Spend por Segmento
- ✓ Compras Web vs Tienda





## 10. Conclusiones Finales

La arquitectura Medallion permite un pipeline organizado, limpio y escalable.

La separación en capas Bronze/Silver/Gold facilitó el mantenimiento y comprensión del flujo.

El uso de Delta Lake garantizó confiabilidad, versionamiento y eficiencia en las tablas.

Unity Catalog brindó gobernanza, control de acceso y orden en los datos.

El workflow permitió automatizar por completo el ETL.

Los dashboards generados demostraron el valor final del pipeline analítico.